Исследование видимости брендов P&G в российском генеративном поиске

Аналитический кейс: Yandex Search с AI / Нейро

Настоящий документ объединяет пять аналитических блоков: блок подготовки данных и формирования итоговых таблиц (combined_table.*, site_statistics_with_percent.*), четыре исследования по гипотезам H1–H4, а также стратегическое KPI-исследование H5 с кодом для генерации артефактов в graphs/h5/.

Логика кейса строится на следующем принципе: генеративный поиск в Яндексе (режим «Поиск с AI» / «Нейро») формирует ответ, анализируя несколько проиндексированных источников, синтезируя из них итоговый текст и приводя ссылки на исходные материалы. Это означает, что попадание бренда в сгенерированный ответ напрямую зависит от того, насколько широко и качественно бренд представлен в «слое источников», которые Яндекс отбирает для синтеза.

---

1. Подготовка данных и формирование итоговых таблиц

Краткое резюме

В работе задействованы два CSV-экспорта. Первый содержит блок запросов — в ряде выгрузок он сопровождается блоком результатов во второй секции того же файла. Второй экспорт содержит блок результатов генеративной выдачи. Из-за такой «двухтабличной» структуры в одном файле стандартное чтение CSV нередко завершается ошибкой разбора (ParserError), поэтому применяется безопасный парсинг с выделением секций по текстовым маркерам.

На выходе пайплайна формируются две ключевые таблицы:

- combined_table.csv и combined_table.xlsx — каждая строка соответствует одному запросу и объединяет его семантику с результатами генеративной выдачи.
- site_statistics_with_percent.csv и site_statistics_with_percent.xlsx — агрегированная статистика по доменам источников, извлечённых из поля «Текст Алисы».

Методика чтения файлов и нормализации доменов воспроизводима и задокументирована на уровне кода.

Исследовательская задача

Необходимо собрать единый датасет, пригодный для проверки аналитических гипотез. Датасет должен включать: (1) запросы с атрибутами частоты, категории и тематической области; (2) характеристики генеративной выдачи — наличие ответа, перечень источников, метки присутствия P&G, конкурентов и маркетплейсов; (3) агрегаты, достаточные для расчёта долей и приоритизации площадок.

Исходные файлы

- search-analysis-1773606579429.csv — содержит секцию === ЗАПРОСЫ === (и в отдельных выгрузках — секцию результатов следом).
- search-analysis-1773508336746.csv — содержит секцию === РЕЗУЛЬТАТЫ ЯНДЕКС / АЛИСА ===.

Выходные таблицы и их структура

combined_table. (одна строка = один запрос)*

- Ключ: ID
- Семантика: Запрос, Категория (brand / category / comparative / advisory), Область (diapers / shampoos / …)
- Спрос: Частота
- Генеративная выдача: Топ, Есть Алиса, Текст Алисы (список источников), флаги P&G, Конкуренты, Маркетплейсы

site_statistics_with_percent. (одна строка = один домен)*

- Упоминания, Уникальные запросы, Суммарная частота, Средняя частота
- Доли: % от всех упоминаний, % от всех запросов, % от всей частоты
- Срезы по Категория и Область

Технические решения

1. Чтение CSV с BOM и секциями. Для надёжной работы используется encoding='utf-8-sig', а текст между маркерами секций вырезается программно.

2. Сборка combined_table. Таблица запросов (=== ЗАПРОСЫ ===) объединяется с таблицей результатов (=== РЕЗУЛЬТАТЫ ЯНДЕКС / АЛИСА ===) по ключу ['ID','Запрос','Категория','Область'] через левое соединение.

3. Сборка site_stats. Источники из поля «Текст Алисы» разбиваются построчно, затем разворачиваются в длинный формат через операцию explode.

4. Нормализация доменов. Приведение к нижнему регистру, удаление префиксов http(s)://, www., обрезка пути после /, удаление спецсимволов (*). Это устраняет дублирование одного и того же домена из-за различных URL-форм.

5. Частотно-взвешенные показатели. Доли по источникам считаются как от общего числа/спроса; частотно-взвешенные метрики показывают, какую долю реального поискового спроса покрывает присутствие в выдаче.

Эталонный код пайплайна

```
import pandas as pd
from io import StringIO

QUERIES_PATH = "search-analysis-1773606579429.csv"
RESULTS_PATH = "search-analysis-1773508336746.csv"

def extract_section_from_file(path, start_marker, end_marker=None):
    with open(path, 'r', encoding='utf-8-sig') as f:
        text = f.read()
    start = text.find(start_marker)
    if start == -1:
        raise ValueError(f'Start marker not found: {start_marker}')
    text = text[start + len(start_marker):]
    if end_marker:
        end = text.find(end_marker)
        if end != -1:
```

```
            text = text[:end]
    return text.strip()

queries_csv = extract_section_from_file(
    QUERIES_PATH,
    start_marker='=== ЗАПРОСЫ ===',
    end_marker='=== РЕЗУЛЬТАТЫ ЯНДЕКС / АЛИСА ==='
)
queries_df = pd.read_csv(StringIO(queries_csv))

results_csv = extract_section_from_file(
    RESULTS_PATH,
    start_marker='=== РЕЗУЛЬТАТЫ ЯНДЕКС / АЛИСА ==='
)
results_df = pd.read_csv(StringIO(results_csv))

queries_df.columns = queries_df.columns.str.strip()
results_df.columns = results_df.columns.str.strip()

combined_df = pd.merge(
    queries_df, results_df,
    on=['ID','Запрос','Категория','Область'],
    how='left'
)

combined_df = combined_df[[
    'ID','Запрос','Частота','Категория','Область',
    'Топ','Есть Алиса','Текст Алисы','P&G','Конкуренты','Маркетплейсы'
]].sort_values('ID').reset_index(drop=True)

combined_df.to_csv('combined_table.csv', index=False, encoding='utf-8-sig')
combined_df.to_excel('combined_table.xlsx', index=False)
```

Контроль качества данных

После сборки рекомендуется выполнить минимальный набор проверок:

- Убедиться, что combined_df.ID уникален (или уникальна комбинация ключей объединения).
- Проверить долю пустых значений в поле «Текст Алисы» и распределение флага «Есть Алиса» — это позволяет оценить покрытие генеративными ответами.
- Sanity-check по частоте: отрицательных или нулевых значений быть не должно; при обнаружении — исключить или явно задокументировать.

---

2. Гипотеза H1: нехватка экспертного и редакционного покрытия брендов P&G

Краткое резюме

Цель — проверить, связана ли видимость P&G в генеративном ответе с качеством экспертно-редакционного слоя источников. Поскольку генеративный ответ строится на

основе найденных материалов, тип и авторитетность источников (медицинские порталы, редакционные издания, коммерческие площадки) потенциально влияют на вероятность рекомендательного упоминания бренда.

В рамках кейса H1 реализована как proxy-классификация доменов по ключевым словам — без ручной разметки — с последующим сравнением структуры источников между тремя группами запросов: P&G visible, Only competitors и No brands. Все результаты и артефакты находятся в graphs/h1/.

Исследовательский вопрос

Насколько сильнее выражен expert/editorial-слой в ответах, где доминируют конкуренты, по сравнению с ответами, где присутствует P&G? Если разрыв существенный — это свидетельствует о том, что бренд уступает в «доверительном» слое источников и поэтому реже попадает в рекомендательный ответ.

Данные и артефакты

Таблицы:

- combined_table.xlsx
- graphs/h1/h1_group_summary.xlsx
- graphs/h1/h1_weighted_summary.xlsx
- graphs/h1/h1_query_level_stats.xlsx

Графики:

- graphs/h1/h1_source_mix_by_group.png
- graphs/h1/h1_expert_editorial_share.png
- graphs/h1/h1_weighted_expert_editorial_share.png
- graphs/h1/h1_expert_editorial_boxplot.png
- graphs/h1/h1_expert_editorial_by_query_type.png
- graphs/h1/h1_scatter_sources_vs_expert_editorial.png

Метрики и методология

Запросы разбиваются на три группы:

- p_and_g_present — если P&G = True
- competitor_only — если P&G = False и Конкуренты = True
- no_brands — если P&G = False и Конкуренты = False

Домены из поля «Текст Алисы» разбиваются построчно и разворачиваются через explode. Каждый домен получает proxy-класс по ключевым словам:

- expert_like — медицинские маркеры: med, doc, clinic, stomat и т.д.
- editorial_like — медийные маркеры: journal, mag, parents, review и т.д.
- marketplace_like — retail-маркеры: ozon, wildberries, market.yandex и т.д.
- other — всё остальное

Ключевая метрика: Expert+Editorial Share, % = (expert_sources + editorial_sources) / total_sources × 100.

Устойчивость проверяется тремя способами: средние доли по группам (unweighted), частотно-взвешенные доли (weighted по полю Частота) и боксплот распределений — чтобы оценить не только среднее, но и вариативность внутри групп. При необходимости применяется непараметрический тест Манна–Уитни для сравнения распределений.

Мини-код статистической проверки

```
import pandas as pd
from scipy.stats import mannwhitneyu

q = pd.read_excel('graphs/h1/h1_query_level_stats.xlsx')
x = q.loc[q['brand_group']=='p_and_g_present',
         'expert_editorial_share_pct'].dropna()
y = q.loc[q['brand_group']=='competitor_only',
         'expert_editorial_share_pct'].dropna()
res = mannwhitneyu(x, y, alternative='two-sided')
print(res.statistic, res.pvalue)
```

Интерпретация результатов

Для оценки гипотезы следует открыть graphs/h1/h1_group_summary.xlsx и сравнить avg_expert_editorial_share_pct между группами p_and_g_present и competitor_only.

- Гипотеза подтверждается, если столбец Only competitors заметно выше на графиках h1_expert_editorial_share.png и h1_weighted_expert_editorial_share.png, а боксплот (h1_expert_editorial_boxplot.png) показывает смещение распределения вверх у конкурентной группы.
- Если разрыв проявляется только в unweighted, но исчезает в weighted — проблема характерна для «длинного хвоста», а не для массового спроса. Стратегически это меняет расстановку приоритетов.

Ограничения

Proxy-разметка по домену не определяет реальный тип страниц и авторитетность конкретных изданий или клиник — это быстрый сигнал, не полноценная разметка. Следующий уровень детализации — ручной аудит топ-доменов или классификация через внешние справочники, однако это выходит за рамки данного кейса. Ограничение важно честно оговорить при защите.

Рекомендации и KPI

Если H1 подтверждается, стратегия должна целенаправленно усиливать expert/editorial-слой вокруг брендов.

KPI:

- E/E Coverage (frequency-weighted): weighted_expert_editorial_share_pct в группе p_and_g_present + целевой прирост Δ.
- Advisory E/E Coverage: avg_expert_editorial_share_pct внутри Категория = advisory.
- Target-platform penetration: рост упоминаний на доменах с наибольшей долей частоты среди условно-редакционных/экспертных площадок.

Практические действия:

- Контент-партнёрства на площадках, которые уже регулярно цитируются в генеративной выдаче (берутся из site_statistics_with_percent.xlsx и топ-доменов из graphs/h1/).
- Создание экспертных материалов: интервью врачей, трихологов, педиатров; протоколы ухода; FAQ-структуры.
- Семантическое покрытие advisory/category-запросов с формулировками, совпадающими с реальными поисковыми запросами пользователей.

3. Гипотеза H2: слабая локализация и индексация брендового контента P&G

Краткое резюме

H2 проверяет, в какой мере P&G уступает в category-запросах (когда бренд не упоминается явно) из-за недостаточного присутствия локальных брендовых доменов (.ru / .рф). В таких запросах генеративная выдача вынуждена опираться на внешние русскоязычные домены и маркетплейсы, поскольку собственный контентный след бренда слаб.

В кейсе H2 реализована в «устойчивой» версии без анализа путей страниц: сравниваются доли локальных брендовых доменов P&G и внешних RU-доменов в источниках.

Исследовательский вопрос

В category-запросах действительно ли «локальный брендовый слой» P&G ниже, чем у конкурентов, и вытесняется внешними RU-источниками либо маркетплейсами?

Данные и артефакты

Таблицы:

- combined_table.xlsx
- graphs/h2/h2_group_summary.xlsx
- graphs/h2/h2_weighted_summary.xlsx
- graphs/h2/h2_query_stats.xlsx

Графики:

- graphs/h2/h2_visibility_share.png
- graphs/h2/h2_local_brand_domains_compare.png
- graphs/h2/h2_source_composition_category_queries.png
- graphs/h2/h2_queries_with_local_pg_brand.png
- graphs/h2/h2_weighted_local_brand_domains_compare.png
- graphs/h2/h2_local_pg_share_by_area.png
- graphs/h2/h2_top_domains_category_queries.png

Метрики и методология

Анализ ограничен строками с Категория == "category". Домены классифицируются на четыре группы:

- local P&G brand domains — домен .ru/.рф/.su с бренд-маркерами P&G (pampers, oralb, pantene и т.д.)
- local competitor brand domains — аналогично, но для конкурентов
- local external RU domains — RU-домен, не являющийся маркетплейсом и не брендовым
- marketplaces — домены с retail-маркерами

Ключевые показатели: доля P&G visible среди category-запросов; доля локальных брендовых доменов P&G в источниках; доля запросов с хотя бы одним локальным брендовым доменом P&G; частотно-взвешенные версии всех перечисленных метрик.

Интерпретация

- Если h2_visibility_share.png показывает низкую долю P&G visible в category-запросах, а h2_local_brand_domains_compare.png и h2_weighted_local_brand_domains_compare.png фиксируют, что доля локальных брендовых доменов P&G ниже конкурентной — гипотеза получает подтверждение.
- h2_source_composition_category_queries.png помогает понять, кто замещает брендовый слой: внешние RU-сайты или маркетплейсы.

Ограничения

Proxy-классификация по домену не позволяет судить о наличии статей или FAQ на конкретных страницах. Это сознательное упрощение: в исходных данных источники часто представлены только доменами без URL-путей. Для усиления аргумента при защите можно добавить короткий ручной аудит 10–15 страниц на официальных RU-сайтах брендов.

Рекомендации и KPI

Если гипотеза подтверждается, необходима локальная контентная инфраструктура на RU-доменах брендов P&G и активное присутствие на внешних RU-площадках, которые чаще всего попадают в источники генеративной выдачи.

KPI:

- Category Visibility, weighted: доля спроса (по Частота) в category-запросах, где P&G visible = True.
- Local brand footprint: weighted_local_pg_brand_share_pct и share_queries_with_local_pg_brand + целевой прирост Δ.
- External RU leverage: рост присутствия на топ-внешних RU-доменах из h2_top_domains_category_queries.png.

---

4. Гипотеза H3: advisory-запросы как главная зона слабости P&G

Краткое резюме

H3 проверяет, является ли сегмент advisory (консультационные запросы) слабейшим звеном для P&G. В этом типе запросов пользователь описывает проблему и ожидает совета, а генеративная выдача агрегирует рекомендации из найденных источников. Именно консультационный сегмент наиболее сильно зависит от внешних площадок, и именно здесь отсутствие экспертного контентного слоя ощущается острее всего.

H3 сравнивает видимость P&G по всем типам запросов и отдельно анализирует advisory против остальных.

Исследовательский вопрос

Ниже ли доля P&G visible в advisory-запросах, чем в brand/category/comparative, и отличается ли advisory по составу источников — больше внешних доменов и маркетплейсов, меньше брендовых?

Данные и артефакты

Таблицы:

- combined_table.xlsx
- graphs/h3/h3_type_summary.xlsx
- graphs/h3/h3_weighted_type_summary.xlsx
- graphs/h3/h3_advisory_vs_other.xlsx
- graphs/h3/h3_query_stats.xlsx
- graphs/h3/h3_advisory_area_summary.xlsx

Графики:

- graphs/h3/h3_pg_visibility_by_query_type.png
- graphs/h3/h3_weighted_pg_visibility_by_query_type.png
- graphs/h3/h3_advisory_vs_other_pg_visibility.png
- graphs/h3/h3_source_mix_by_query_type.png
- graphs/h3/h3_advisory_vs_other_source_mix.png
- graphs/h3/h3_boxplot_pg_brand_share_advisory_vs_other.png
- graphs/h3/h3_advisory_pg_visibility_by_area.png

Метрики и методология

Для каждого типа запросов вычисляются: P&G visibility rate, competitor-only rate, no-brands rate, marketplace_share_pct, pg_brand_share_pct, external_non_marketplace_share_pct. Обязательна частотно-взвешенная видимость (weighted_pg_visibility_rate) — чтобы не смешивать количество запросов с реальным объёмом спроса. Боксплот для pg_brand_share_pct в advisory vs others показывает, насколько часто advisory-ответы вообще опираются на брендовые домены.

Интерпретация

- Если h3_pg_visibility_by_query_type.png и особенно h3_weighted_pg_visibility_by_query_type.png показывают минимальное значение у Advisory, а h3_source_mix_by_query_type.png демонстрирует большую долю внешних доменов и меньшую долю источников P&G — гипотеза подтверждается, и advisory превращается в «зону роста №1».
- h3_advisory_pg_visibility_by_area.png позволяет выбрать приоритетную продуктовую категорию внутри advisory-сегмента (например, diapers vs shampoos).

Ограничения

Классификация источников выполняется по доменам и маркерам, а не по смысловому содержанию нейроответа. H3 фиксирует структурный сигнал — где P&G виден и на каких типах источников держится ответ — но не оценивает тональность или ранжирование брендов внутри ответа.

Рекомендации и KPI

При подтверждении H3 advisory-сегмент следует развивать как отдельный продуктовый трек «moment of choice»:

- Контент в формате «проблема → причина → решение → критерии выбора → подбор продукта».
- Форматы сравнения и подборок на площадках, наиболее часто цитируемых генеративной выдачей (по site_statistics_with_percent.xlsx).

- Экспертный слой в синергии с H1 — ответы на реальные «боли» пользователей.

KPI:

- Advisory Visibility (weighted): доля спроса по advisory-запросам, где P&G visible.
- Advisory Source Mix shift: снижение доли «прочих» источников и рост доли контентных/экспертных площадок.
- Advisory Gap burn-down: количество высокочастотных advisory-запросов без P&G должно снижаться спринт за спринтом.

---

5. Гипотеза H4: доминирование маркетплейсов и низкая диверсификация источников

Краткое резюме

H4 охватывает два взаимосвязанных объяснения слабой видимости: во-первых, генеративная выдача избыточно retail-heavy — маркетплейсы доминируют среди источников, и именно там бренду сложнее выделиться. Во-вторых, выдача platform-dependent — она держится на узком наборе доменов, что снижает устойчивость и управляемость брендового присутствия. Концентрация измеряется через долю топ-доменов и индекс HHI.

Исследовательский вопрос

Связаны ли сценарии «P&G виден/не виден» с долей маркетплейсов в источниках (marketplace_share_pct) и с концентрацией источников (малое число уникальных доменов, высокая доля топ-1/топ-3, высокий HHI)?

Данные и артефакты

Таблицы:

- combined_table.xlsx
- graphs/h4/h4_group_summary.xlsx
- graphs/h4/h4_weighted_summary.xlsx
- graphs/h4/h4_query_stats.xlsx
- graphs/h4/h4_type_summary.xlsx

Графики:

- graphs/h4/h4_marketplace_share_by_group.png
- graphs/h4/h4_source_concentration_by_group.png
- graphs/h4/h4_hhi_by_group.png
- graphs/h4/h4_weighted_marketplace_and_concentration.png
- graphs/h4/h4_scatter_marketplace_vs_top1.png
- graphs/h4/h4_marketplace_and_concentration_by_query_type.png
- graphs/h4/h4_top_domains_overall.png

Метрики и методология

Marketplace share: доля доменов с retail-маркерами от общего числа источников запроса. Диверсификация оценивается через unique_domains (число уникальных доменов), top1_domain_share_pct, top3_domains_share_pct и repetition_share_pct.

Концентрация измеряется через HHI (индекс Херфиндаля–Хиршмана) — сумму квадратов долей доменов; максимум равен 10 000 при монополии. Опционально применяется тест Манна–Уитни по marketplace_share_pct и hhi между группами.

Интерпретация

- Если h4_marketplace_share_by_group.png показывает более высокую долю маркетплейсов в группах competitor_only или no_brands — это поддерживает тезис о retail-dominance.
- Если h4_source_concentration_by_group.png и h4_hhi_by_group.png фиксируют более высокую концентрацию там, где присутствие P&G слабее — это свидетельствует о platform-dependence.
- Scatter h4_scatter_marketplace_vs_top1.png наглядно показывает, идут ли «маркетплейс-доминирование» и «высокая концентрация» в одной точке данных.

Ограничения

Marketplace-классификация основана на доменном списке: часть аптек и ритейла может не попасть в нужный класс, если домен не включён в список. HHI измеряет концентрацию по доменам, но не учитывает их вес внутри нейроответа (основной источник vs второстепенный). Это приемлемо для кейсовой аналитики при условии явного упоминания ограничения.

Рекомендации и KPI

Если H4 подтверждается, ключевой стратегический вывод — retail-присутствия недостаточно для победы в генеративной выдаче. Необходима диверсификация источников и баланс между маркетплейсами и контентными площадками.

KPI:

- Marketplace dependency: weighted_marketplace_share_pct по целевым сегментам (advisory/category) должен снижаться за счёт роста доли контентных источников.
- Source diversification: рост unique_domains, снижение top1_domain_share_pct и HHI.
- Platform risk: доля спроса, завязанная на топ-1/топ-3 доменов, взвешенная по частоте.

Практические действия:

- По данным site_statistics_with_percent.xlsx определить «коридор платформ» и расширять набор цитируемых источников: обзоры, редакции, сообщества, экспертные площадки.
- Для доменов с высокой долей частоты создавать страницы и материалы, которые вероятнее будут отобраны как источники генеративного ответа (синергия с H1/H3).

---

6. Гипотеза H5: стратегический KPI и приоритизация роста видимости

Краткое резюме

H1–H4 объясняют причины отставания (экспертный слой, локальность, advisory-провал, retail-доминирование). H5 переводит диагностику в управляемую стратегию и систему KPI:

- вводится KPI «покрытие спроса генеративной видимостью» (frequency-weighted visibility) и «gap по спросу»;
- строится «карта возможностей» по квантилям частоты и типам запросов;
- предлагается алгоритм приоритизации платформ и инициатив по фреймворку RICE (Reach–Impact–Confidence–Effort).

Формулировка гипотезы

Основной недобор P&G в генеративной выдаче концентрируется в верхневороночных сегментах (category / advisory / comparative) и в высокочастотной части спроса. Оптимальная стратегия — не равномерное улучшение по всему фронту, а целенаправленное закрытие наиболее частотных разрывов на платформах с максимальным вкладом в частотное покрытие.

Данные и артефакты

Входные файлы:

- combined_table.xlsx
- site_statistics_with_percent.xlsx

Выходные файлы (папка graphs/h5/):

- graphs/h5/h5_visibility_by_freq_quantile.png
- graphs/h5/h5_weighted_pg_visibility_by_query_type.png
- graphs/h5/h5_gap_by_query_type.png
- graphs/h5/h5_opportunity_scatter.png
- graphs/h5/h5_top_gap_queries.xlsx
- graphs/h5/h5_platform_prioritization.xlsx

KPI-метрики

Weighted P&G Visibility (WPV) — ключевой KPI видимости:

$WPV = (\sum freq(q) \cdot I(PG_visible(q)) / \sum freq(q)) \times 100$

Это доля спроса, покрытая запросами, где P&G уже попадает в генеративный ответ.

Demand Gap — непокрытый спрос:

$Gap = \sum freq(q)$ для PG_not_visible(q)

Можно считать отдельно для competitor_only и no_brands.

Opportunity score на уровне запроса — для сортировки приоритетов:

$Opportunity(q) = freq(q) \cdot w(type) \cdot w(group)$

где w(type) выше для advisory/category/comparative, а w(group) выше для competitor_only — там конкурентная борьба уже идёт.

Platform reach (из site_stats): % от всей частоты по доменам — прокси «сколько спроса проходит через платформу».

Код для генерации H5

```
import os, numpy as np, pandas as pd
import matplotlib.pyplot as plt
os.makedirs('graphs/h5', exist_ok=True)
```

```
def save_plot(filename):
    plt.tight_layout()
    plt.savefig(f'graphs/h5/{filename}', dpi=300, bbox_inches='tight')
    plt.show(); plt.close()

df = pd.read_excel('combined_table.xlsx')
for col in ['P&G','Конкуренты']:
    df[col] = df[col].fillna(False).astype(bool)
df['Категория'] = df['Категория'].astype(str).str.lower()
df['Частота'] = pd.to_numeric(df['Частота'], errors='coerce').fillna(0)

def brand_group(row):
    if row['P&G']: return 'p_and_g_present'
    if row['Конкуренты']: return 'competitor_only'
    return 'no_brands'

df['brand_group'] = df.apply(brand_group, axis=1)
df['pg_visible'] = (df['brand_group']=='p_and_g_present').astype(int)

# Квантили частоты
df['freq_quantile'] = pd.qcut(df['Частота'].rank(method='first'), 4,
    labels=['Q1_low','Q2','Q3','Q4_high'])

# WPV по квантилям
wpv_by_q = (df.groupby('freq_quantile')
    .apply(lambda g: 100*np.average(g['pg_visible'],
        weights=g['Частота'] if g['Частота'].sum()>0 else None))
    .reset_index(name='wpv_pct'))
wpv_by_q['freq_quantile'] = wpv_by_q['freq_quantile'].astype(str)
plt.figure(figsize=(9,5))
plt.bar(wpv_by_q['freq_quantile'], wpv_by_q['wpv_pct'])
plt.title('H5: Frequency-weighted P&G visibility by frequency quantile')
save_plot('h5_visibility_by_freq_quantile.png')

# WPV по типам запросов
order = ['brand','category','comparative','advisory']
type_wpv = (df.groupby('Категория')
    .apply(lambda g: 100*np.average(g['pg_visible'],
        weights=g['Частота'] if g['Частота'].sum()>0 else None))
    .reset_index(name='wpv_pct'))
type_wpv['Категория'] = pd.Categorical(type_wpv['Категория'],
    categories=order, ordered=True)
type_wpv = type_wpv.sort_values('Категория')
plt.figure(figsize=(9,5))
plt.bar(type_wpv['Категория'].astype(str), type_wpv['wpv_pct'])
plt.title('H5: Frequency-weighted P&G visibility by query type')
save_plot('h5_weighted_pg_visibility_by_query_type.png')

# Gap по типам запросов
df['gap_freq'] = np.where(df['pg_visible']==1, 0, df['Частота'])
gap_by_type = df.groupby('Категория')['gap_freq'].sum().reset_index()
gap_by_type['Категория'] = pd.Categorical(gap_by_type['Категория'],
    categories=order, ordered=True)
gap_by_type = gap_by_type.sort_values('Категория')
```

```
plt.figure(figsize=(9,5))
plt.bar(gap_by_type['Категория'].astype(str), gap_by_type['gap_freq'])
plt.title('H5: Demand gap by query type (freq sum where P&G not visible)')
save_plot('h5_gap_by_query_type.png')

# Топ-разрывы: самые частотные запросы без P&G
top_gap = (df[df['pg_visible']==0]
    .sort_values('Частота', ascending=False)
    [['ID','Запрос','Частота','Категория','Область','brand_group']]
    .head(50))
top_gap.to_excel('graphs/h5/h5_top_gap_queries.xlsx', index=False)

# Opportunity scatter
group_to_y = {'competitor_only': 1, 'no_brands': 0}
scatter_df = df[df['pg_visible']==0].copy()
scatter_df['y'] = scatter_df['brand_group'].map(group_to_y).fillna(0)
plt.figure(figsize=(9,5))
plt.scatter(scatter_df['Частота'], scatter_df['y'], alpha=0.6)
plt.title('H5: Opportunity map (frequency vs competitor-only/no-brands)')
save_plot('h5_opportunity_scatter.png')

# Приоритизация платформ
site_stats = pd.read_excel('site_statistics_with_percent.xlsx')
platform_plan = site_stats[['Сайт','% от всей частоты',
    '% от всех запросов','% от всех упоминаний']].head(50).copy()
platform_plan.rename(columns={'% от всей частоты':'Reach_proxy_pct'},
inplace=True)
platform_plan['Impact_score'] = None
platform_plan['Confidence_pct'] = None
platform_plan['Effort_person_weeks'] = None
platform_plan['RICE_score'] = None
platform_plan.to_excel('graphs/h5/h5_platform_prioritization.xlsx',
index=False)
```

Интерпретация H5

- h5_visibility_by_freq_quantile.png: если WPV минимален в Q4_high — это сильный бизнес-аргумент: бренд проигрывает именно в самом массовом спросе.
- h5_gap_by_query_type.png: показывает, где сосредоточен наибольший непокрытый спрос.
- h5_top_gap_queries.xlsx: готовый список запросов-кандидатов для реального контентного плана и партнёрств.
- h5_platform_prioritization.xlsx: заготовка под обоснованную приоритизацию площадок через RICE; Impact, Confidence и Effort заполняются командой вручную.

Приоритизация инициатив через RICE

- Reach: берётся Reach_proxy_pct из site_statistics_with_percent.xlsx или абсолютный Gap-спрос из H5.
- Impact: экспертная оценка — на сколько пунктов WPV вырастет при появлении на площадке. Editorial/expert-площадки дают больший impact для advisory (синергия с H1–H3).

- Confidence: чем чаще домен встречается в источниках (высокие % от всех запросов и % от всей частоты), тем выше вероятность, что улучшение отразится в генеративной выдаче.
- Effort: стоимость и время — контент, PR-материал, партнёрство, SEO-работы.

Ограничения

H5 не оценивает тональность и степень доминирования бренда внутри ответа — только факт присутствия и покрытие спроса. Для целей кейса это корректно: строится система метрик, по которой можно управлять ростом видимости, что соответствует логике KPI-ориентированной стратегии.

Рекомендованный план внедрения

- Недели 1–2: сбор baseline KPI (WPV, Gap), отбор 30–50 топ gap-запросов.
- Недели 3–4: выбор 10–15 приоритетных платформ по RICE, согласование форматов.
- Недели 5–8: производство и размещение контента (advisory/category), экспертные коллаборации.
- Недели 9–10: контрольная выборка запросов, пересбор combined_table, пересчёт KPI.
- Недели 11–12: масштабирование на новые запросы и платформы, обновление roadmap.

Итоговый вывод

H1–H4 формируют диагностическую картину: слабый экспертный слой, недостаточная локальность, advisory-провал, retail-доминирование и высокая концентрация источников. H5 превращает эту картину в операционную систему управления: измеряем базовый WPV, выявляем частотный Gap, выбираем платформы по Reach/Impact/Confidence/Effort и подтверждаем эффект пересчётом KPI на следующем цикле обновления данных. Такой подход непосредственно соответствует механике генеративного поиска, который строит ответы на основе источников и показывает ссылки на них.